

순열-등변 Latin4와 24 GB QLoRA를 이용한 4-프레임 시간 순서 추론

SNU AI Challenge 2026 최종 보고서

1. 문제 정의와 최종 시스템

본 과제는 문장 하나와 무작위 순서로 주어진 네 장의 이미지로 원래 시간 순서를 복원하는 문제다. 정답은 원본 프레임 번호의 나열이 아니라, **현재 입력된 각 이미지가 시간축의 몇 번째인지를** 나타내는 4-순열이다. 한 위치라도 틀리면 전체 샘플이 오답인 Exact Match이므로, 국소적인 frame 비교뿐 아니라 네 장의 전역적인 일관성이 필요하다.

우리의 최종 시스템은 다음과 같다.

deterministic index shuffle + answer transform → Qwen3.6-27B rank32 QLoRA → balanced cyclic Latin4 → original-slot canonicalization → hard majority → lexicographic tie

최종 모델 계약

- Base: Qwen/Qwen3.6-27B, revision 6a9e13bd6fc8f0983b9b99948120bc37f49c13e9
- 학습: 제공된 9,535행 전체, optimizer step 2,726, 2.28694 epochs
- Adapter: QLoRA rank 32, alpha 32, dropout 0.05, unmerged
- 추론: NF4 base, BF16 compute, SDPA, image size 512, batch 1
- 생성: max_new_tokens=64, seed 42, thinking disabled, 순열 하나만 출력
- TTA: 1234, 2341, 3412, 4123, hard vote, lexicographic tie

핵심 기여

1. **순열-등변 좌표 처리.** 입력 순서를 바꿔 얻은 예측을 그대로 투표하지 않고 원래 slot 좌표로 역변환한 뒤 집계한다. 2. **학습-추론 대칭성.** 학습 중 입력 index를 결정론적으로 섞고 정답도 같은 좌표계로 변환해 위치 shortcut을 줄였다. 3. **최소 균형 TTA.** 네 cyclic view만으로 각 원본 이미지가 네 displayed position에 정확히 한 번씩 등장한다. 24-view보다 6배 저렴하면서 실측 점수도 높았다. 4. **실제 24 GB 배치.** 27B base를 NF4로, adapter를 merge하지 않은 채 단일 RTX 3090에서 실행하고 process 외부 NVML sampler로 물리 peak를 측정했다. 5. **재현 가능한 선택.** model tree, adapter, 명령, raw output, CSV를 SHA-256 receipt로 연결하고, 더 많은 epoch/view가 항상 낫다는 가정을 실제 ablation으로 반박했다.

최종 Public score는 **0.93542**다. Public은 test의 70%만 사용하므로 이 점수를 Private 또는 외부 데이터 성능의 보장으로 해석하지 않는다. 그 대신 외부 평가에도 동일한 checkpoint-2726과 동일 추론 코드를 한 번만 적용한다.

2. 데이터 활용과 학습 방법

결정론적 index-shuffle augmentation

네 이미지의 의미는 같아도 입력 slot은 임의적이다. 고정 slot로만 학습하면 모델이 내용이 아니라 위치 prior를 이용할 수 있다. 각 (seed, epoch, Id)를 SHA-256으로 hash해 입력 permutation을 결정하고, 이미지 배열과 Answer를 동시에 변환했다. 같은 seed와 data에서 매번 동일하게 재현되며, test-time에 적용하는 좌표 canonicalization과 수학적으로 같은 변환을 사용한다.

QLoRA 학습

Qwen3.6-27B의 vision-language 사전학습 능력을 유지하면서 24 GB 추론 제약에 맞추기 위해 4-bit QLoRA를 사용했다. language attention/MLP projection에 rank32 adapter를 적용하고 base는 quantized 상태로 유지했다. batch 1, gradient accumulation 8, BF16 compute, image area 512×512 상당, seed 42를 사용했다. 최종 checkpoint는 global step 2,726이며 adapter tensor 512개가 모두 finite임을 확인했다.

최종 run은 labeled 9,535행 전체를 학습에 사용했다. 따라서 이 모델을 같은 데이터의 holdout으로 사후 평가하면 누수가 된다. Qwen3.6 checkpoint 선택에는 그 수치를 쓰지 않았으며, Public 제출과 비용·안정성 ablation만 사용했다. 초기 설계 단계의 clean954 split은 8B/Qwen3.5 파이프라인과 permutation 방법을 검증하는 surrogate로만 사용했다.

Checkpoint-axis 선택

epoch 증가가 단조 성능 향상을 보장하지 않는다는 관찰을 반영해 checkpoint를 하나의 명시적인 탐색 축으로 취급했다. 마지막 구간에서 2,726과 3,400을 보존하고 같은 generation 계열로 비교했다. checkpoint-3400 TTA12는 0.93542로 checkpoint-2726 Latin4를 넘지 못했다. 따라서 더 긴 학습을 “성능 향상”으로 포장하지 않고, 계산량이 더 작은 2,726을 채택했다.

외부 자원과 데이터

학습 데이터는 운영진 제공 데이터만 사용했다. 외부 상용 API, 외부 labeling API, 외부 데이터셋, 다른 모델의 pseudo-label, row-level model mixing은 사용하지 않았다. Base model은 대회 cutoff 이전 공개된 Apache-2.0 Qwen3.6-27B 한 개다. RunPod RTX A6000은 학습 장비로만, 로컬 RTX 3090은 최종 추론과 재현 검증에 사용했다.

3. Canonical Latin4 추론과 자원 최적화

좌표계 문제

예를 들어 view 2341에서 모델이 출력한 label은 그 view 안의 위치를 의미한다. 이를 원본 1234 view의 label과 직접 투표하면 서로 다른 좌표계를 합치는 오류가 생긴다. 각 view 출력 p 와 입력 permutation v 로부터 원래 네 이미지의 시간 순서를 다시 계산한 뒤 canonical Answer로 변환했다. parser는 [1,2,3,4]의 순열만 허용하고, 설명문이나 중복 숫자는 실패로 기록한다.

왜 Latin4인가

1234, 2341, 3412, 4123은 각 원본 이미지가 각 displayed position에 정확히 한 번씩 나타나는 Latin square다. 따라서 input-position exposure는 네 view만으로 완전 균형이다. 24개 모든 permutation은 coverage를 늘리지만 이미 position bias가 0인 이후에는 noisy view를 더하며 계산량만 6배가 될 수 있다.

단일 checkpoint 비교	Public	views	결과
ckpt2726 Latin4 confidence tie-break	0.92670	4	hard보다 낮음
ckpt2726 Latin4 hard	0.93542	4	최종 선택
ckpt2726 full TTA24 hard	0.93193	24	Latin4 대비 -0.00349
ckpt3400 TTA12 hard	0.93542	12	동점, 비용 3배

confidence tie-break은 생성 token confidence가 정답 확률로 잘 보정됐다는 보장이 없어 오히려 점수를 낮췄다. 최종 규칙은 top vote가 하나면 그것을, exact tie이면 canonical permutation의 lexicographic minimum을 고른다. Public의 개별 문항 정답을 역추정하거나 수동으로 행을 고치지 않았다.

24 GB 실행

Base를 NF4, compute를 BF16, attention을 SDPA로 두고 batch 1, 단일 resident model로 순차 처리했다. adapter merge, dequantization, multi-model ensemble은 사용하지 않았다. checkpoint-2726 Latin4 전체 819행의 결과는 다음과 같다.

- 819/819 완료, 3,276 views, parse failure 0
- 평균 16.4693초/row, 총 약 3시간 45분
- physical peak 22,710,861,824 bytes(약 21.15 GiB)
- 예상 밖 CUDA process 0

PyTorch allocator 값만으로는 driver와 non-PyTorch allocation을 놓칠 수 있어, model load 이전부터 작업 종료 이후까지 NVML device-used memory를 0.5초 간격으로 측정했다. 이는 대회 단일 RTX 3090 24 GB 제약 안에서 실제 실행 가능성을 보인다.

4. 실험 결과, 오류 분석, 비용

Ablation

측	비교	관찰	결론
모델/초기 checkpoint	Q35-1073 Latin4 confidence	0.92844	27B fallback
Q36 checkpoint	step1074 Latin4 confidence	0.93019	학습 진행으로 개선
집계	step2726 confidence → hard	0.92670 → 0.93542	confidence 제거
view 수	step2726 TTA4 → TTA24 hard	0.93542 → 0.93193	추가 view가 악화
학습·view	step2726 TTA4 → step3400 TTA12	0.93542 → 0.93542	추가 비용 무이득

위 표는 Public 70%에 대한 제한된 관찰이다. 여러 제출 중 최댓값을 고르는 과정 자체가 Public에 과적합될 수 있다. 따라서 최종 코드는 최댓값을 만든 복잡한 조합이 아니라, 동점 후보 중 더 이른 checkpoint와 더 적은 view를 고정했다. Private와 외부 데이터에서는 이 사전 고정 규칙을 변경하지 않는다.

오류 분석

가장 분명한 오류 측은 입력 **permutation sensitivity**였다. 초기 모델에서 view별 예측이 달라지는 행이 많았고, canonical multi-view는 이 변동을 줄였다. 남은 오류는 미세한 상태 변화, 반복 동작, 장면 전환과 카메라 이동, 문장과 시각 단서의 불일치가 섞여 있을 것으로 예상된다. 다만 test label이 없으므로 개별 test 행의 오류 유형을 정답인 것처럼 단정하지 않았다.

추론 자체의 technical failure는 최종 run에서 없었다. 819행 모두 네 view가 유효한 순열로 parse됐고 fallback identity가 사용되지 않았다. TTA24가 16개 행에서 Latin4 hard와 다른 답을 만들었으나 Public score는 0.00349 낮았다. 이는 더 많은 변환이 항상 robustness를 높이지 않으며, 균형 이후의 marginal view quality가 중요하다는 실험적 근거다.

구축 비용

- API 비용: 0원. 외부 상용 API를 사용하지 않음
- 학습: 사비 RunPod RTX A6000, 표시 단가 USD 0.53/hour
- 추론: 보유 RTX 3090 한 장
- 최종 adapter: 약 638 MB; base snapshot: 약 55.6 GB
- 최종 inference: 약 3.75 GPU-hours

Provider invoice와 가정하지 않은 전기·감가상각 비용은 정확한 총액으로 환산하지 않았다. 계산 절약의 핵심은 Latin4, single checkpoint, unmerged adapter, checkpoint-2726 조기 종료다. TTA24 대신 Latin4를 쓰면 최종 추론량을 83.3% 줄이면서 Public 점수는 오히려 높아졌다.

5. 재현성, 장점과 한계

재현 절차

GitHub 저장소는 base model manifest, adapter manifest, 최종 wrapper와 단위 테스트를 포함한다. Base는 29개 파일/15개 shard의 size와 SHA-256을 확인하고, adapter release는 archive와 내부 두 파일을 모두 검증한다.

- Base: ``python -B scripts/download_weights.py --manifest configs/weights/qwen36-27b-final.manifest.json --output models/Qwen3.6-27B``
- Adapter: ``python -B scripts/download_final_adapter.py --output weights/qwen36-checkpoint2726``
- Inference: `python -B -m scripts.run_final_inference --data-dir data --resume`

최종 wrapper가 NF4/BF16/SDPA/512/64/seed42, Latin4 orders, original-coordinate canonicalization, hard vote를 명시한다. 결과는 `submission.csv`, `audit.jsonl`, `metrics.json`으로 저장된다. raw audit를 보존해 parser와 집계를 독립 재계산할 수 있다. 채점된 핵심 source SHA-256은 inference `7ab46f47...d414`, TTA `c3a3df4f...7bc2`, parser `e2f9844b...71c8`, modeling `3fcd1e73...4778` 이다.

장점

- 입력 순열 변화에 수학적으로 일관된 canonicalization
- 네 view만으로 완전한 position balance
- 27B 모델을 실제 24 GB GPU에서 실행
- 단일 checkpoint·단일 model로 규정과 외부 평가 재현성이 명확
- 성능이 나빠진 confidence/TTA24/추가 epoch도 결과에 포함한 정직한 ablation

한계

- 최종 Q36은 full-data 학습이라 leakage-free 동일 모델 holdout 비교가 없다.
- Public 70%의 반복 관찰 때문에 모델 선택 overfitting 가능성이 있다.
- 다중 seed, fold별 안정성, 대규모 수동 semantic error annotation이 없다.
- rank32와 rank8의 동일 checkpoint·동일 split 대조가 없다.
- Private 및 외부 데이터 성능은 최종 평가 전까지 알 수 없다.

결론

최종 시스템은 가장 큰 모델이나 가장 많은 TTA를 단순히 택한 것이 아니다. **학습과 추론의 좌표 변환을 일치시키고, position balance를 만족하는 최소 Latin4를 사용하며, 실제 RTX 3090 메모리 안에서 재현 가능한 checkpoint-2726을 고정했다.** 더 긴 checkpoint와 24-view는 추가 비용에도 개선되지 않았고 confidence 집계는 악화됐다. 이 결과를 바탕으로 성능, 논리적 타당성, 자원 효율성과 재현성을 함께 갖춘 단일 모델을 외부 데이터 평가와 코드 검증에 제출한다.

상세 수치·SHA·artifact 출처는 `docs/final_results.json`, 가중치 저작권은 `docs/model_licenses.md`, 실행 지침은 저장소 `README.md`에 기록했다.